

* B_{ij} متغیر تصادفی است که وزن را به خود اوج نشان می‌دهد

* F_k بردار ویژگی خود k ام (سطر k ام ماتریس F)

یکسای مشاهده شده و یکسای Hidden

$$\mathcal{L} = p(B|f) = \sum_{i,j: i < j} \log p(B_{ij}) = \sum_{i,j: i < j} B_{ij} \log \theta_{ij} - \theta_{ij} - \log(B_{ij}!) = \sum_{i,j: i < j} B_{ij} \log F_i^T F_j - F_i^T F_j - \log(B_{ij}!)$$

$$\nabla_{F_k} \mathcal{L} = \sum_{j=1}^{k-1} \left(B_{jk} \frac{F_j}{F_j^T F_k} - F_j \right) + \sum_{j=k+1}^N \left(B_{kj} \frac{F_j}{F_j^T F_k} - F_j \right) \xrightarrow{B_{ji} = B_{ij}} \nabla_{F_k} \mathcal{L} = \sum_{i=1}^N \left(B_{ik} \frac{F_i}{F_i^T F_k} - F_i \right)$$

قدرت $B_{ii} = F_i^T F_i$ \rightarrow مقدار hidden

* مقادیر از B_{ij} که دیده شده با مقدار A_{ij} و مقادیر دیده نشده با Expectation به دست می‌آیند!

بنا بر این فصول به روز رسانی داریم: آخرین مقدار B_{ij} (تقریبی) \rightarrow f مربوط به خود k ام، در مرحله t ام E_m و $m+1$ ام (تقریبی)

$$f_k^{t,m+1} = f_k^{t,m} + \epsilon_k \left\{ \sum_{i \in H} \left(f_i^{t-1,m} f_k^{t-1,m} \frac{f_i^{t,m}}{f_i^{b,m,T} f_k^{b,m}} - f_i^{t,m} \right) \right\}$$

hidden

$$\text{Observe} \left\{ \sum_{i \in O} \left(A_{ik} \frac{f_i^{t,m}}{f_i^{b,m,T} f_k^{b,m}} - f_i^{t,m} \right) \right\}$$

* B_{ij} دو حالت دارد، اگر مشاهده شده باشد که همواره مقدار A_{ij} که ورودی صله است می‌گیرد اگر مشاهده نشده باشد

با مقدار امید B_{ij} مشاهده بقیه جایگزین می‌شود که در هر گام E این مقدار بر مبنای آخرین F به دست

آمده به صورت $F_i^T F_j$ محاسبه می‌شود، ولی برای افزایش سرعت محاسبه (با اینکه احتمال و آگاری است) در محاسبه امید

از آخرین مقادیر F استفاده می‌کنیم یعنی به جای $f_j^{t-1,m}$ مقدار $f_j^{t,m}$ فارسی می‌دهیم که روابط به روز رسانی به صورت زیر می‌شود:

$$f_k^{t,m+1} = f_k^{t,m} + \epsilon_k \left\{ \sum_{i \in H} \left(f_i^{t,m,T} f_k^{t,m} \frac{f_i^{t,m}}{f_i^{b,m,T} f_k^{b,m}} - f_i^{t,m} \right) \right\}$$

صفر

$$\sum_{i \in O} \left(A_{ik} \frac{f_i^{t,m}}{f_i^{b,m,T} f_k^{b,m}} - f_i^{t,m} \right)$$

$$\Rightarrow f_k^{t,m+1} = f_k^{t,m} + c_k \left\{ \sum_{i \in O} \left(\frac{cd_{ik}}{f_i^{b_{gm}T} f_k^{b_{gm}}} - f_i^{t,m} \right) \right\}$$

$$\Rightarrow f_k^{t,m+1} = f_k^{t,m} + c_k \left\{ \underbrace{\sum_{i \in O} \left[\left(\frac{cd_{ik}}{f_i^{b_{gm}T} f_k^{b_{gm}}} - 1 \right) f_i^{t,m} \right]}_{\text{grad}_k} \right\}$$

$$* \text{grad}_k = \sum_{i \in O} \left[\left(\frac{cd_{ik}}{f_i^{b_{gm}T} f_k^{b_{gm}}} - 1 \right) f_i^{t,m} \right]$$

$$= \sum_i \left[\underbrace{w_{ik} \left(\frac{cd_{ik}}{f_i^{b_{gm}T} f_k^{b_{gm}}} - 1 \right)}_{Q_{ik}} f_i^{t,m} \right] = [Q \ F]_{\text{سطر } k \text{ ام}}$$

$$* Q \triangleq (F^{b_{gm}} \ F^{b_{gm}T})^{0-1} \circ A \circ W - W$$

Hadamard Inverse
Hadamard product

به فرم ماتریسی داریم:

$$\begin{cases} F^{\text{new}} = (I + CQ) F^{\text{old}} \\ Q = (F^{\text{old}} \ F^{\text{old}T})^{0-1} \circ A \circ W - W \\ C = \text{diag}(c_1, c_2, \dots, c_N) \end{cases}$$

که c_i کیرمب بهبود خطا یا هر یکی برابر و به ازای افزایش خطا $\frac{1}{2\alpha}$ برابر می‌شود

که α مقدار انتخاب شده! این محاسبات برای افزایش سرعت ماتریسی انجام می‌شود!

انواع مختلفی مقداردهی اولیه برای k می سازیم که شامل:

* از یک توزیع گاما با α و β تصادفی

* از یک توزیع Normal با میانگین تصادفی

* همه مقدارهای k و از توزیع Uniform بین 0 و 0.5


که بهترین نتایج برای حالت آخر است و مقدار حدود 0.3 است!

برای پیدا کردن بهترین نقطه شروع k و ایجاد k موازی به این صورت عمل می کند که به تعداد k تصادفی ای را می کشد و تعداد حداکثر 20 دور به روز می کشد پس از این (این k های حاصل بهترین k در مرحله بعد وجود دارد به علاوه مقادیر حیدیه تصادفی k ، تعداد k های تصادفی در اینها همان است و در هر مرحله به صورت خفیف این تعداد کاهش می یابد تا در مرحله آخر تمام k های حاصل بهترین k های مرحله قبل باشد که تعداد این مراحل 100 در نظر گرفته شده است در آخر هم k تا k حاصل بدون محدودیت تعداد به روز رسانی می شوند

k برای استفاده می شود اکثری از توان پردازشی تعداد core k می گذاریم که برای نتایج حاصل 264 بوده!

یعنی در مجموع 3278 حالت مختلف برای نقطه شروع بررسی شده


برای پیدا کردن بهترین k روی داده های Observed که کلج های داده های Train را دارد برای مقادیری از k الگوریتم اجرا شده که حاصل به صورت زیر است:



* مقدار اولیه k تصادفی بین مقادیر 0 و 1 انتخاب شده و در حال انتخاب k اولیه که در بالا گفته شد برای مشتق تر شدن تاثیر k در نظر گرفته شده

* بهترین مقدار k حدود 12 است که در بقیه مراحل مقدار 12 برای آن انتخاب شده!

نتایج کامل تر در قسمت 6 ناز دوم گزارش شده است



$$f_{il} \sim \text{Gamma}(a, b)$$

$$B_{ij} \sim \text{poisson}(f_i^T f_j)$$

توجه شود که در بین دو plate متغیر f مشترک وجود دارد!


$$P(f, B; a, b) = \prod_{n=1}^N \prod_{l=1}^K P(f_{nl}; a, b) \prod_{n, m: n < m} P(B_{mn} | f_m, f_n)$$

$$\Rightarrow P(f_{n^*l^*} | \text{other}) = \frac{P(f_{n^*l^*}; a, b) \prod_{\substack{m=1 \\ m \neq n^*}}^N P(B_{mn^*} | f_{n^*}, f_m)}{\sum_{f_{n^*l^*}} \left\{ P(f_{n^*l^*}; a, b) \prod_{\substack{m=1 \\ m \neq n^*}}^N P(B_{mn^*} | f_{n^*}, f_m) \right\}}$$

$$\Rightarrow \ln P(f_{n^*l^*} | \text{other}) = (a-1) \ln f_{n^*l^*} - b f_{n^*l^*} + \sum_{\substack{m=1 \\ m \neq n^*}}^N \left\{ -f_{n^*}^T f_m + B_{mn^*} \ln f_{n^*}^T f_m \right\} + \text{const}$$

⚠ که در محاسبه این مشکل می‌توانیم مدل بسوی را در نظر بگیریم

اصل جدیدی که داریم:



$$\begin{cases} f_i \sim \text{Gamma}(a, b) \\ c_{ijl} \sim \text{poisson}(f_{il} f_{jl}) \end{cases}$$

$$B_{ij} = \sum_l c_{ijl}$$

مجموعه B های دیده نشده
دیده شده

توجه شود که در بین دو plate تعدادی مشترک وجود دارد!

$$P(f, c, B_0) = \prod_{n=1}^N \prod_{l=1}^K \left\{ P(f_{nl}; a, b) \right\} \prod_{m, n: m \in n} \prod_{l=1}^K \left\{ P(c_{mnl} | f_{ml}, f_{nl}) \right\} \prod_{\{m, n | B_{m,n} \in B_0\}} \left\{ P(B_{m,n} | c_{m,n}) \right\}$$

* برای B های latent از آنجا که با مشخص شدن c مربوط به آن مقدار B هم مشخص است، این B ها را از مدل حذف کرده و فقط برای B های مشاهده شده متغیری در مدل داریم

* یا توجه به افتادن شدن c به اثبات می کنیم که همان توزیع قبلی را دارد:

$$\begin{aligned} & \left. \begin{aligned} A &\sim \text{poisson}(\lambda_1) \\ B &\sim \text{poisson}(\lambda_2) \end{aligned} \right\} \Rightarrow P(\underbrace{A+B}_c = \alpha) = \sum_{\beta=0}^{\alpha} \frac{P(A+B=\alpha | B=\beta) P(B=\beta)}{P(A=\alpha-\beta)} \\ & \Rightarrow P(c=\alpha) = e^{-\lambda_1-\lambda_2} \sum_{\beta=0}^{\alpha} \frac{\lambda_1^{\alpha-\beta} \lambda_2^{\beta}}{(\alpha-\beta)! \beta!} = \frac{e^{-(\lambda_1+\lambda_2)}}{\alpha!} \sum_{\beta=0}^{\alpha} \underbrace{\binom{\alpha}{\beta} \lambda_1^{\alpha-\beta} \lambda_2^{\beta}}_{(\lambda_1+\lambda_2)^{\alpha}} \Rightarrow c \sim \text{poisson}(\lambda_1+\lambda_2) \end{aligned}$$

$$B_{ij} \sim \text{poisson}\left(\underbrace{\sum_l f_{il} f_{jl}}_{f_i^T f_j}\right) \Rightarrow \begin{cases} \text{بنابر این اصل جدید همان} \\ \text{نتیجه قبلی با اصل قبلی تار} \end{cases}$$

2

★ برای تقریب $p(f, c | B_0)$ بارش Variational تابع $q(f, c)$ را در نظر گرفته و بین c_{mn} و f_{nl}

استقلال فرض کرده و $q_{f_{nl}}$ و $q_{c_{mn}}$ را در ادامه می‌نویسیم.

$$q(f, c) = \prod_{n=1}^N \prod_{l=1}^K q_{f_{nl}} \prod_{m,n:m \leq n} q_{c_{mn}}$$

حساب $p(f_{n^*l^*} | \text{other})$:

$$\begin{aligned} p(f_{n^*l^*} | \text{other}; a, b) &= \frac{\prod_{n=1}^N \prod_{l=1}^K \{p(f_{nl}; a, b)\} \prod_{m,n:m \leq n} \prod_{l=1}^K \{p(c_{ml} | f_{ml}, f_{nl})\} \prod_{\{m,n | B_{mn} \in B_0\}} \{p(B_{mn} | c_{mn})\}}{\sum_{f_{n^*l^*}} \prod_{n=1}^N \prod_{l=1}^K \{p(f_{nl}; a, b)\} \prod_{m,n:m \leq n} \prod_{l=1}^K \{p(c_{ml} | f_{ml}, f_{nl})\} \prod_{\{m,n | B_{mn} \in B_0\}} \{p(B_{mn} | c_{mn})\}} \\ &= \frac{p(f_{n^*l^*}; a, b) \prod_{\substack{m=1 \\ m \neq n^*}}^N p(c_{m n^*l^*} | f_{m l^*}, f_{n^*l^*})}{\sum_{f_{n^*l^*}} \{p(f_{n^*l^*}; a, b) \prod_{\substack{m=1 \\ m \neq n^*}}^N p(c_{m n^*l^*} | f_{m l^*}, f_{n^*l^*})\}} \\ &\propto f_{n^*l^*}^{a-1} e^{-b f_{n^*l^*}} \prod_{\substack{m=1 \\ m \neq n^*}}^N e^{-f_{m l^*} f_{n^*l^*}} (f_{m l^*} f_{n^*l^*})^{c_{m n^*l^*}} \\ &\propto f_{n^*l^*}^{a-1 + \sum_{\substack{m=1 \\ m \neq n^*}}^N c_{m n^*l^*}} \exp \left\{ - \left(b + \sum_{\substack{m=1 \\ m \neq n^*}}^N f_{m l^*} \right) f_{n^*l^*} \right\} \end{aligned}$$

$$\Rightarrow p(f_{n^*l^*} | \text{other}; a, b) \sim \text{Gamma} \left(a + \sum_{\substack{m=1 \\ m \neq n^*}}^N c_{m n^*l^*}, b + \sum_{\substack{m=1 \\ m \neq n^*}}^N f_{m l^*} \right)$$

حساب $q_{f_{n^*l^*}}$:

$$\Rightarrow \ln p(f_{n^*l^*} | \text{other}; a, b) = \text{ثابت} + \left(a - 1 + \sum_{\substack{m=1 \\ m \neq n^*}}^N c_{m n^*l^*} \right) \ln f_{n^*l^*} - \left(b + \sum_{\substack{m=1 \\ m \neq n^*}}^N f_{m l^*} \right) f_{n^*l^*}$$

$$\Rightarrow E_{-f_{n^*l^*}} [\ln p(f_{n^*l^*} | \text{other}; a, b)] =$$

$$\text{ثابت} + \left(a - 1 + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[c_{m n^*l^*}] \right) \ln f_{n^*l^*} - \left(b + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[f_{m l^*}] \right) f_{n^*l^*}$$

$$\Rightarrow q_{f_{n^*l^*}}^* \propto f_{n^*l^*}^{(a-1 + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[c_{m n^*l^*}])} \exp \left\{ - \left(b + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[f_{m l^*}] \right) f_{n^*l^*} \right\}$$

$$\Rightarrow q_{f_{n^*l^*}}^* \sim \text{Gamma} \left(a + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[c_{m n^*l^*}], b + \sum_{\substack{m=1 \\ m \neq n^*}}^N E[f_{m l^*}] \right)$$

$$\begin{aligned}
 P(c_{m^*n^*} | \text{other}; a, b) &= \frac{\prod_{n=1}^N \prod_{l=1}^k \{P(f_{nl}; a, b)\} \prod_{m,n: m \in \mathcal{M}} \prod_{l=1}^k \{P(c_{mnl} | f_{ml}, f_{nl})\} \prod_{\{m,n | B_{m,n} \in B_0\}} \{P(B_{mn} | c_{mn})\}}{\sum_{c_{m^*n^*}} \prod_{n=1}^N \prod_{l=1}^k \{P(f_{nl}; a, b)\} \prod_{m,n: m \in \mathcal{M}} \prod_{l=1}^k \{P(c_{mnl} | f_{ml}, f_{nl})\} \prod_{\{m,n | B_{m,n} \in B_0\}} \{P(B_{mn} | c_{mn})\}} \\
 &= \frac{\prod_{l=1}^k \{P(c_{m^*n^*l} | f_{m^*l}, f_{n^*l})\} P(B_{m^*n^*} | c_{m^*n^*})}{\sum_{c_{m^*n^*}} \left\{ \prod_{l=1}^k \{P(c_{m^*n^*l} | f_{m^*l}, f_{n^*l})\} P(B_{m^*n^*} | c_{m^*n^*}) \right\}} \\
 &= \begin{cases} \prod_{l=1}^k \text{poisson}(c_{m^*n^*l}; f_{m^*l}, f_{n^*l}) & B_{m^*n^*} \in B_H \\ \text{Multinomial}(c_{m^*n^*1}, \dots, c_{m^*n^*k}; B_{m^*n^*}, \frac{f_{m1} f_{n1}}{\sum_q f_{mq} f_{nq}}, \dots, \frac{f_{mk} f_{nk}}{\sum_q f_{mq} f_{nq}}) & B_{m^*n^*} \in B_0 \end{cases}
 \end{aligned}$$

* حالت Multinomial:


$$\frac{e^{-\sum_l f_{m^*l} f_{n^*l}} \prod_l (f_{m^*l} f_{n^*l})^{c_{m^*n^*l}}}{\prod_l c_{m^*n^*l}!} \delta(B_{m^*n^*} - \sum_l c_{m^*n^*l})$$

$$P(c_{m^*n^*} | \text{other}; a, b) = \frac{\exp\left\{-\sum_l f_{m^*l} f_{n^*l}\right\} \left(\sum_l f_{m^*l} f_{n^*l}\right)^{B_{m^*n^*}}}{B_{m^*n^*}!}$$

تنها حالتی که در اینجا غیر صفر است
حالتی است که $B_{m^*n^*}$ و چون
فرض تعدادی بواسن است
عبارت توزیع جمع بواسن است

$$= \frac{B_{mn}!}{\prod_l c_{mnl}!} \frac{\prod_l (f_{ml} f_{nl})^{c_{mnl}}}{\left(\sum_l f_{ml} f_{nl}\right)^{B_{mn}}} \delta(B_{mn} - \sum_l c_{mnl})$$

$$= \binom{B_{mn}}{c_{mn1}, \dots, c_{mnk}} \prod_{l=1}^k \left(\frac{f_{ml} f_{nl}}{\sum_q f_{mq} f_{nq}} \right)^{c_{mnl}} \delta(B_{mn} - \sum_l c_{mnl})$$

محاسبی $q_{c_{m^*n^*}}$ برای $B_{m^*n^*}$ ای latent: 

$$\Rightarrow \ln p(c_{m^*n^*} | \text{other}; a, b) = \sum_{l=1}^k \ln \text{poisson}(c_{m^*n^*l}; f_{m^*l} f_{n^*l})$$


$$\Rightarrow \ln p(c_{m^*n^*} | \text{other}; a, b) = \sum_{l=1}^k \left\{ -\frac{f_{m^*l}}{f_{n^*l}} + c_{m^*n^*l} \ln \frac{f_{m^*l}}{f_{n^*l}} - \ln(c_{m^*n^*l}!) \right\}$$

$$\Rightarrow E_{-c_{m^*n^*}} \left\{ \ln p(c_{m^*n^*} | \text{other}; a, b) \right\} = \text{cte} + \sum_{l=1}^k \left\{ c_{m^*n^*l} (E[\ln f_{m^*l}] + E[\ln f_{n^*l}]) - \ln(c_{m^*n^*l}!) \right\}$$

$$\Rightarrow q_{c_{m^*n^*}}(c_{m^*n^*}) \propto \frac{\prod_l \exp \left\{ c_{m^*n^*l} (E[\ln f_{m^*l}] + E[\ln f_{n^*l}]) \right\}}{\left(\prod_l c_{m^*n^*l}! \right)}$$

$$\Rightarrow q_{c_{m^*n^*}}(c_{m^*n^*}) \propto \prod_{l=1}^k \frac{\exp \left\{ (E[\ln f_{m^*l}] + E[\ln f_{n^*l}]) \right\}^{c_{m^*n^*l}}}{c_{m^*n^*l}!} \Rightarrow \text{روی تمام } l \text{ یکسان است}$$

$$\Rightarrow q_{c_{m^*n^*l^*}} \sim \text{poisson} \left(\exp \left\{ (E[\ln f_{m^*l^*}] + E[\ln f_{n^*l^*}]) \right\} \right)$$

مسابی $q_{c_{m^*n^*}}$ برای $B_{m^*n^*}$: Observe 

$$\Rightarrow \ln p(c_{m^*n^*} | \text{other}; a, b) = \ln \left[\left(\sum_{\ell} c_{m^*n^* \ell}! \right) - \left(\sum_{\ell} h(c_{m^*n^* \ell}) \right) + \left(\sum_{\ell} c_{m^*n^* \ell} \left[h f_{m^* \ell}^T + h f_{n^* \ell}^T - h \left(\sum_{q} f_{m^* q}^T f_{n^* q}^T \right) \right] \right) \right]$$

$$\Rightarrow E_{-c_{m^*n^*}} \{ \ln p(c_{m^*n^*} | \text{other}; a, b) \} = \ln \left[\left(\sum_{\ell} c_{m^*n^* \ell}! \right) - \left(\sum_{\ell} h(c_{m^*n^* \ell}) \right) + \sum_{\ell} c_{m^*n^* \ell} (E[h f_{m^* \ell}^T] + E[h f_{n^* \ell}^T]) \right] - E[h f_{m^*}^T f_{n^*}] \sum_{\ell} c_{m^*n^* \ell}$$

$$\Rightarrow q_{c_{m^*n^*}}(c_{m^*n^*}) \propto \frac{\exp \{ \ln \left[\left(\sum_{\ell} c_{m^*n^* \ell}! \right) \right] \} \prod_{\ell} \exp \{ c_{m^*n^* \ell} (E[h f_{m^* \ell}^T] + E[h f_{n^* \ell}^T]) \}}{\left(\prod_{\ell} \exp \{ \ln(c_{m^*n^* \ell}!) \} \right) \exp \{ E[h f_{m^*}^T f_{n^*}] \sum_{\ell} c_{m^*n^* \ell} \}}$$

$$\Rightarrow q_{c_{m^*n^*}}(c_{m^*n^*}) \propto \frac{\left(\sum_{\ell} c_{m^*n^* \ell}! \right)}{\left(\prod_{\ell} c_{m^*n^* \ell}! \right)} \frac{\prod_{\ell} \exp \{ c_{m^*n^* \ell} (E[h f_{m^* \ell}^T] + E[h f_{n^* \ell}^T]) \}}{\exp \{ E[h f_{m^*}^T f_{n^*}] \sum_{\ell} c_{m^*n^* \ell} \}}$$

$$\Rightarrow q_{c_{m^*n^*}}(c_{m^*n^*}) \propto \binom{B_{m^*n^*}}{c_{m^*n^*1}, \dots, c_{m^*n^*k}} \frac{\prod_{\ell} \exp \{ (E[h f_{m^* \ell}^T] + E[h f_{n^* \ell}^T]) \}^{c_{m^*n^* \ell}}}{\exp \{ E[h f_{m^*}^T f_{n^*}] B_{m^*n^*} \}} \delta(B_{m^*n^*} - \sum_{\ell} c_{m^*n^* \ell})$$

$$\Rightarrow \left\{ \begin{array}{l} q_{c_{m^*n^*}}(c_{m^*n^*}) \sim \text{Multinomial}(c_{m^*n^*1}, \dots, c_{m^*n^*k}; B_{m^*n^*}, p_1, \dots, p_k) \\ p_{\ell} = \frac{\exp \{ E[h f_{m^* \ell}^T] + E[h f_{n^* \ell}^T] \}}{\sum_i \exp \{ E[h f_{m^* i}^T] + E[h f_{n^* i}^T] \}} \end{array} \right.$$

$$q_{c_{m^*n^*}}(c_{m^*n^*}) \sim \text{Multinomial}(c_{m^*n^*1}, \dots, c_{m^*n^*k}; \beta_{m^*n^*}, p_1, \dots, p_k)$$

برای $\beta_{m^*n^*} \in B_0$ ←

$$f_{l^*} = \frac{\exp\{E[h f_{m^*l^*}] + E[h f_{n^*l^*}]\}}{\sum_i \exp\{E[h f_{m^*i}] + E[h f_{n^*i}]\}}$$

$$q_{c_{m^*n^*l^*}} \sim \text{poisson}\left(\underbrace{\exp\{(E[h f_{m^*l^*}] + E[h f_{n^*l^*}])\}}_{\lambda_{m^*n^*l^*}}\right)$$

برای $\beta_{m^*n^*} \in B_H$ ←

$$f_{n^*l^*}^* \sim \text{Gamma}\left(\underbrace{a + \sum_{\substack{m=1 \\ m \neq n^*}} E[c_{mn^*l^*}]}_{\alpha_{n^*l^*}}, \underbrace{b + \sum_{\substack{m=1 \\ m \neq n^*}}^{\infty} E[f_{ml^*}]}_{\beta_{n^*l^*}}\right)$$

$$E[h f_{n^*l^*}] = -\ln \beta_{n^*l^*} + \psi(\alpha_{n^*l^*}) \rightarrow \text{Digamma function}$$

$$E[f_{n^*l^*}] = \alpha_{n^*l^*} / \beta_{n^*l^*}$$

$$E[c_{m^*n^*l^*}] = \begin{cases} \lambda_{m^*n^*l^*} & \beta_{m^*n^*} \in B_H \\ \beta_{m^*n^*} \times f_{m^*n^*l^*} & \beta_{m^*n^*} \in B_0 \end{cases}$$

غیر قابل بازی برداری :

$$f'_{m^*n^*l^*} = \frac{\exp\{E[h f_{m^*l^*}] + E[h f_{n^*l^*}]\}}{\sum_i \exp\{E[h f_{m^*i}] + E[h f_{n^*i}]\}}$$

$$\lambda'_{m^*n^*l^*} = \exp\{(E[h f_{m^*l^*}] + E[h f_{n^*l^*}])\}$$

$$\alpha'_{n^*l^*} = a + \sum_{\substack{m=1 \\ m \neq n^*}} E[c_{mn^*l^*}]$$

$$\beta'_{n^*l^*} = b + \sum_{\substack{m=1 \\ m \neq n^*}}^{\infty} E[f_{ml^*}]$$

کہ باہر روز رسانی معادلات معمولات کہ توزیع اراضتیں میں کنند بہ دست آورده ہیں چون بہ دنبال ستار امید

$$\hat{B}_{m^*n^*} = E \left\{ \sum_{l=1}^k c_{m^*n^*l} \right\} = \sum_{l=1}^k \lambda_{m^*n^*l}$$

B کی latent متغیر:

برای Sampling از روش Gibbs، استفاده میکنیم که نحوه تشکیل توزیع مثل قسمت قبل است و محاسبات لازم برای به دست آوردن توزیع یک هم درست قبل انجام شد که به صورت زیر است:

$$p(f_{n^*l^*} | other; a, b) \sim \text{Gamma} \left(a + \sum_{\substack{m=1 \\ m \neq n^*}}^N c_{m^*n^*l^*}, b + \sum_{\substack{m=1 \\ m \neq n^*}}^N f_{m^*l^*} \right)$$

$$p(c_{m^*n^*} | other) = \begin{cases} \prod_{l=1}^k \text{poisson}(c_{m^*n^*l}; f_{m^*l} f_{n^*l}) & B_{m^*,n^*} \in B_H \\ \text{Multinomial}(c_{m^*n^*1}, \dots, c_{m^*n^*k}; B_{m^*,n^*}, \frac{f_{m^*1} f_{n^*1}}{\sum_q f_{m^*q} f_{n^*q}}, \dots, \frac{f_{m^*k} f_{n^*k}}{\sum_q f_{m^*q} f_{n^*q}}) & B_{m^*,n^*} \in B_0 \end{cases}$$

* اثبات بودن B_0 بقیه متغیرها را با نمونه‌گیری باروش Gibbs به دست آورده و بعد از مرحله‌ای

Burn-in، با تعدادی نمونه‌گیری مشابه قسمت قبل به دنبال توزیع c های مربوط به B های خاصه

نشده هستیم که یعنی تخمین λ آنرا که با Moments اول به دست می‌آید

$$\lambda_{m^*n^*l^*} \approx \frac{1}{r} \sum_{i=1}^r c_{m^*n^*l^*}^{(i)}$$

و متادیر B های Latent را به دست می‌آوریم:

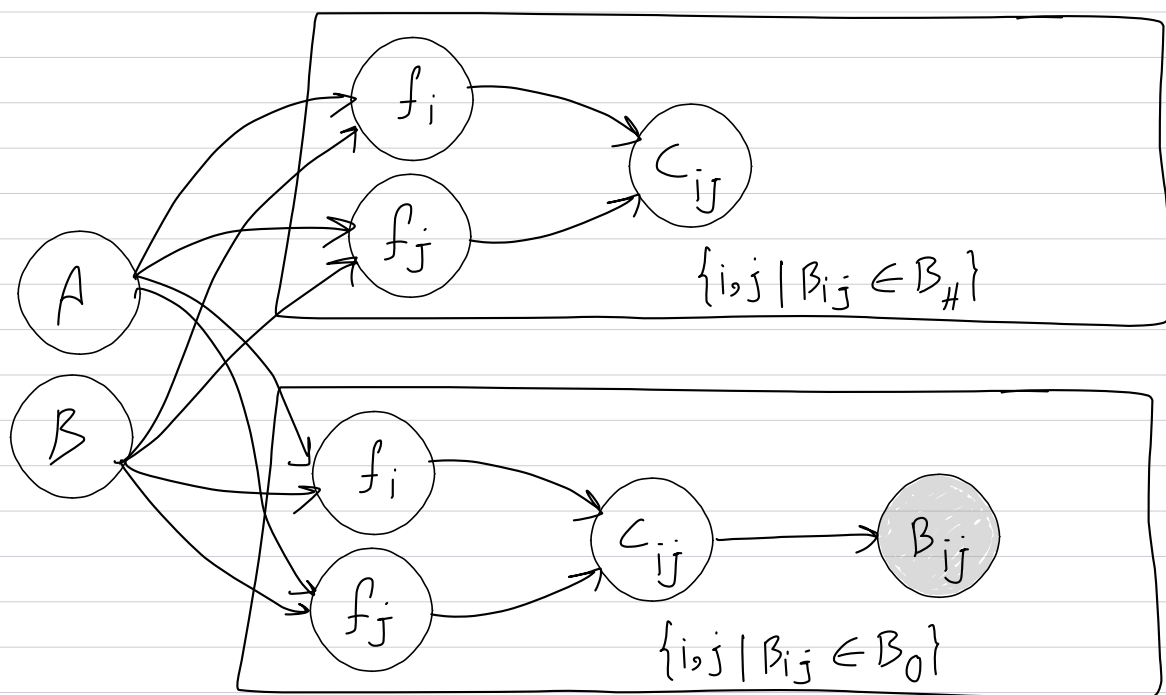
$$\hat{B}_{m^*n^*} = E \left\{ \sum_{l=1}^k c_{m^*n^*l} \right\} = \sum_{l=1}^k \lambda_{m^*n^*l}$$

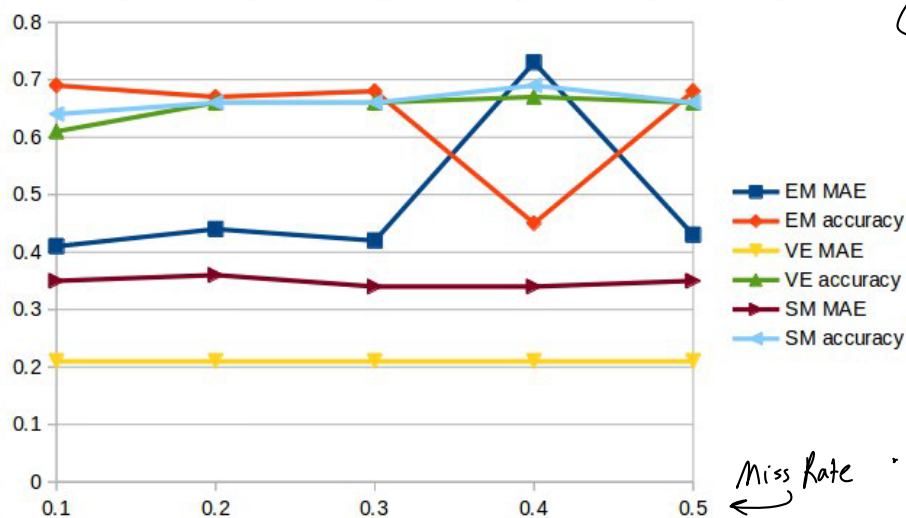
* در پیاده سازی برای یافتن بهترین مقادیر a و b به صورت parallel الگوریتم برای مقادیر تعادلی a و b ۱۰۰۰ بار اجرا شده و بهترین مقادیر پیدا شده است.

این مقادیر تعادلی بر حسب امید یعنی $\frac{a}{b}$ و واریانس یعنی $\frac{a}{b^2}$ انتخاب شده که از انتخاب Uniform بین 1 تا 20 بوده و در آخر هم مقادیر انتخاب شده برای توزیع prior در حالتی که $k=2$ است میکنیم حدود 4 دارند و واریانس هم از مقادیر کم به دلیل تاثیر محض prior (دوری کرده و حدود 8 است).

البته می توان بر مبنای توزیع مقادیر \mathcal{CA} این میکنیم رانتجین زد! و چون prior است محدودی درست باشد کفایت می کند و در Learning تاثیر آن کم می شود.

* راه دیگری که برای یافتن a و b به ذهن می آید در نظر گرفتن انتخاب به عنوان R_V و دفعی کردن محاسبه آنها در محاسبات Variational است که با بررسی انجام شده این مدل تاثیر در روابط دیگر متغیر ندارد و تنها ناپایداری آن کاهش محاسبات برای پیدا کردن a و b است





* دو خودارزیر حاصل MAE و Accuracy برای


حالات k و MissRate های مختلف است

* این نتایج چون برای Result نهایی انجام

شد، تمام Methodها های گفته شده برای بررسی

~ 3000 ستار اولیه در EM، بررسی 1000

ستار n و b به صورت معادنی روی 64 core انجام شده. Miss Rate



* بهترین نتایج مربوط به VE با $MAE \sim 0.2$ و $Accuracy \sim 66\%$ است.

از آنجا که حاصل تقریباً مستقل از k و MissRate شده !!! احتمالاً به دلیل Search گسترده که در ستار اولیه


و به ازای آن k ستار مختلف n و b و ستار معادنی

مختلف جستجو فصل انجام شده به ازای تمام k حاصل

خوب یافت شده.

مثلاً تنها با یک ستار معادنی شروع \rightarrow الگوریتم EM روی دیات

بزرگ حاصل متقابل را دارد که تاثیر k مشخص است:



* با توجه به این که در Variational فرض کمی استقلال اغانه ترتیب به مدل اولیه داریم انتقال من رود که Sampling نتایج بهتری دهد اما از آنجا که محاسبات Sampling زیاد بوده است بهبود کامل آن فرمت نشده و چیزی که قطعی است حاصل آن نمی تواند از Variational بهتر شود و این نشان دهنده ی این است که استقلال کمی اضافه شده در Variational ضایع بوده .

* از موارد گفته شده و تاثیر مثبت جستجو اولیه می توان ضمیمه کرد که مدل ارائه شده ضعیف است و جستجوی اولیه تاخیر زیادی روی نتایج می گذارد به حدی که تغییر پارامتر مدل را کم اهمیت کرده است !!

* روش EM بر روی دیتاست بزرگ $MAE = 0.54$ و $Accuracy = 95\%$ است .
(بقیه ابرار مولانی شد)

اعداد خودارگانی صفحه ی قبل :

	K (miss=0.2)	4	8	10	12	14
EM	MAE	0.45	0.43	0.43	0.44	0.44
	accuracy	66%	68%	68%	66%	68%
VE	MAE	0.21	0.2	0.23	0.2	0.22
	accuracy	64%	66%	65%	65%	65%
SM	MAE	0.34	0.34	0.36	0.33	0.36
	accuracy	65%	66%	65%	66%	66%
	16	18	20	30	50	100
EM	0.41	0.43	0.42	0.44	0.43	0.43
	68%	67%	70%	68%	66%	67%
VE	0.19	0.22	0.21	0.22	0.22	0.25
	66%	65%	69%	65%	65%	65%
SM	0.35	0.35	0.35	0.36	0.36	0.36
	66%	65%	71%	67%	66%	65%

	miss (K=12)	0.1	0.2	0.3	0.4	0.5
EM	MAE	0.41	0.44	0.42	0.73	0.43
	accuracy	69%	67%	68%	45%	68%
VE	MAE	0.21	0.21	0.21	0.21	0.21
	accuracy	61%	66%	66%	67%	66%
SM	MAE	0.35	0.36	0.34	0.34	0.35
	accuracy	64%	66%	66%	69%	66%

★ چون درگیری حالات از نتایج جواب های عجیب مثل همه عناصر 1 دیده می شود یکی از مشکلات

می تواند توزیع poisson باشد که حامل ضرب داخلی به سمت صفر برود و توزیع در حول صفر جمع می شود

و برای رفع این موضوع می توان پارامتری در حامل ضرب داخلی ضرب کرده که با scale کردن از

سمت صفر دور شود! (این پارامتر در یادگیری دخلی شود)

★ ضرب داخلی معیاری مناسب برای ثبات در مجموعه ویژگی نیست و مثال های

دلیل بر ضعف آن وجود دارد صرفاً در حد ایده می توان به جای ضرب داخلی برای تعیین ثبات افراد

مدل پیچیده تری قرار داد مثلاً استفاده از مدل بدون جهت گرایی با فاکتورهای از نوع sigmoid

که هم از یک شبکه عصبی برای پیدا کردن ویژگی های سطح بالاتر است. که برای این کار مدل اصلی

هم باید بدون جهت و Moraviz شود.

(حدوداً می دانم که می توان بید Boltzmann Machine قرار داد که هم از یک شبکه عصبی است و وزن

های آن شبکه به عنوان پارامتری مدل است)

★ از آنجا که در شبکه های اجتماعی اکثر وزن ها صفر است می توان توجه کرد که در حمایت می توان برای ماتریکس های

sparse بهبود (یاد کرد performance اجرا را بهبود داد.

* یک فایل `dataset.py` شامل `class` به نام `DATASET` است که `lead` و محاسبه خطا نهایی را انجام می دهد

* فایل `Main.py` که فایل اصلی است و به کلاس برای آموزش و تست برای

`parallel` کردن کدها وجود دارد، در انتها کداز `class` استفاده شده و `Dataset` مورد

تغیر و محاسبه `miss` و `k` داده شده است.

* فایل `Seed.txt` که `Seed` تمام محاسبه های را مشخص می کند!